大数据招聘岗位数据分析 · 项目完整报告

> **作者**：大数据技术专业（专科）大三在读
> **目标岗位**：数据助理 / 初级数据分析 / 大数据开发助理
> **技术栈**：Python（Pandas / NumPy / Matplotlib）· 数据清洗 · 分组聚合 · 可视化 · 业务解读
> **数据规模**：原始 4,100 行 × 15 字段 → 清洗后 **3,498 行 × 19 字段**
> **一句话结论**：在「大数据开发」方向的岗位市场里，**学历决定能不能过筛，经验决定能不能上桌，SQL 决定第一步迈得进不进得去。**

---

1. 项目概述

1.1 项目背景

我是大数据技术专业的专科大三学生，2026 年秋招是第一次真正面对就业市场。摆在我面前的问题很具体：招聘网站上的岗位动辄几十页，但我不知道该看哪些、能投哪些、还差什么。

「大数据」这个方向在招聘市场上有两层含义：一层是大数据**开发**（写 Java 做平台、搭 Hadoop/Spark 集群），一层是大数据**分析**（写 SQL 做报表、做业务分析）。两者的门槛、技能栈、薪资结构完全不同，但招聘网站的岗位描述往往混在一起。作为专科生，我还额外面对一个现实约束：**学历筛选会在我看到岗位之前就把一部分机会过滤掉。**

与其凭感觉海投，不如先用数据把市场看清楚。这个项目就是回答三个问题：

1. 我这个学历，在这个市场上实际能投的岗位有多少？
2. 这些岗位要什么技能，我应该按什么顺序补？
3. 我锁定的目标地域（川渝），供给量到底够不够？

1.2 项目目标

层次	目标	完成标准
数据层	把一份带脏值的原始招聘数据整理成可分析的干净表	关键字段完整率 ≥ 99%，去重后无主键重复
分析层	从学历、地域、技能、经验四个维度刻画岗位市场结构	每个维度给出分组统计结果，不只做总量描述
决策层	把统计结论翻译成「投哪里、补什么、怎么排优先级」	每条结论对应一个可立即执行的求职动作
交付层	产出可复现的脚本与可对外展示的报告	脚本一键跑通，报告中的数字与脚本输出逐项一致

1.3 项目流程

```
原始 CSV（4,100 × 15）
   │
   ├─ ① 质量诊断：重复、缺失、脏值、格式混乱分布盘点
   ├─ ② 去重：整行重复 602 条 → 剩余 3,498
   ├─ ③ 结构化解析：从「地区经验学历」列表串中回收城市/经验/学历
   ├─ ④ 缺失处理：回填优先，dropna 兜底
   ├─ ⑤ 类型转换：薪酬文本 → 月薪下限/上限/中点（数值）
   ├─ ⑥ 异常值处理：领域兜底 + IQR 标记（只标记不删）
   ▼
清洗后主表（3,498 × 19）→ 分组聚合 → 四维可视化 → 业务结论
```

1.4 我的角色

全流程独立完成：数据质量诊断、清洗规则设计、指标口径定义、聚合分析、图表设计与绘制、结论提炼与报告撰写。其中「用哪一列回填哪一列」「异常值删还是留」这类判断，都需要结合业务常识做取舍，不是跑通代码就算完成。

---

2. 数据源与采集方案

2.1 数据来源

本项目数据来自**和鲸社区公开数据集**（大数据岗位招聘信息，CSV 格式），非自行爬取。选择公开数据集而非爬虫，原因有三点：

1. **合规无风险。**学生作品集不适合背负爬虫合规争议；招聘网站的《用户协议》普遍禁止自动化采集，一旦被追究，项目本身的价值会被抵消。
2. **结构已整理，可以把精力放在分析上。**原始数据集是抓取后整理的结果，字段已半结构化，适合练习清洗与建模，而不是消耗在反爬对抗上。
3. **可复现、可验证。**任何人拿到同一份文件都能跑出同样结果，这对作品集的可信度是加分项。

2.2 数据规模与字段结构

原始数据 **4,100 行 × 15 字段**，覆盖 44 类职位名称、69 家公司，发布时间集中在 **2022 年 11 月**（2022-11-02 至 2022-11-14），属于同一时间窗口的快照，横向可比性较好。

字段分组	字段	说明
岗位标识	职位名称、公司名称	无缺失
岗位属性	工作经验要求、学历要求	各有约 11.6% 缺失
地域	工作地点、城市地区	有缺失，可从结构化列回收
薪酬	薪酬	文本格式，含「千 / 万 / 年 / ·13薪」等多种写法
企业	公司规模、公司类型、公司福利、公司标签	规模缺失 776 条，福利缺失 1,041 条
内容	职位描述或任职要求	技能词频分析的主要文本来源
结构化兜底	地区经验学历	`["城市-区县","经验","学历"]` 列表字符串，**4,100 条 100% 可解析**
时间	发布时间、更新时间	无缺失，均在 2022-11

其中 `地区经验学历` 是这份数据的关键列——它把城市、经验、学历压缩在一个页面结构化字符串里，正好可以用来修复其他列的缺失与脏值。这是整个清洗工作的主要突破口。

2.3 数据边界声明（重要）

这份数据的定位必须说清楚，否则结论会被误用：

- 它是**「大数据开发」主题的垂直切片**，不是全市场招聘数据：职位名称仅 44 类、公司仅 69 家，`大数据开发工程师` 一个名称就占了 1,270 条（36.3%）。这意味着技能词频会被少数公司的模板化 JD 放大。
- 它是**单一时间点快照**（2022-11），不能用于趋势判断（如「某技能是否在升温」）。
- 它**不是川渝限定数据**，全国岗位混在一起，川渝需要单独筛选，而筛选后样本量会显著变小。

因此本报告的所有结论限定在「2022 年 11 月、大数据开发方向、本数据集覆盖的公司范围内」。主动说明这一点不是示弱，而是让结论站得住。

---

3. 数据预处理与清洗

3.1 质量问题诊断

动代码之前先做诊断，把问题按类型列清楚，再决定每条怎么处理。

问题类型	具体情况	影响
整行重复	完全重复的行 **602 条**（占 14.7%）	会让所有频次统计虚高约 15%
缺失值	工作经验 475、学历 476、工作地点 532、城市地区 475、公司规模 776、公司福利 1,041	分组统计会出现「空组」，交叉分析样本流失
脏值串列	`学历要求` 混入「11-16发布」等发布日期串约 35 条；`工作经验要求` 混入「大专」「10-12发布」各 1 条	学历枚举被污染，直接分组会多出错误类别
转义不一致	同一个值被拆成两类：`在校生/应届生` 与 `在校生\/应届生`	分组计数被拆散，小类被低估
格式混乱	`薪酬` 有「8千-1.2万」「15-20万/年」「1.5-2万·13薪」等 6 种以上写法	无法直接计算均值/中位数
口径不一	`工作地点` 是省市区串，`城市地区` 是「城市-区县」	需要统一到「城市」这一层才能对比

3.2 五步清洗

第 1 步：去重

先按整行去重（602 条），把 **4,100 行压到 3,498 行**。再用「公司名称 + 职位名称 + 工作地点 + 发布时间」做业务主键二次校验，发现仍有 3 条重复——这 3 条是职位描述不同的近似记录，保留不删，因为主键相同并不等于业务事实相同。

这一步真正的难点是「不要过度去重」。 如果按「公司名称 + 职位名称」去重，这 3,498 条会瞬间塌缩到只剩 77 条——因为数据集中同一个「大数据开发工程师」在同一家公司出现了成百上千次（不同城市、不同事业部、不同批次）。一旦这么删，岗位供需的量级信息就被彻底抹掉了。去重必须锚定「一条记录代表一个岗位发布」这个业务定义，而不是图省事按字符串匹配。

第 2 步：从结构化列解析并回填

把 `地区经验学历` 用 `ast.literal_eval` 解析成 `[城市-区县, 经验, 学历]` 三元组，**4,100 条全部解析成功（失败 0 条）**，再用它回填：

- 学历缺失 476 条 → 回填 476 条
- 经验缺失 475 条 → 回填 475 条
- 城市字段统一到「城市」层级，派生 `城市` / `区县` 两列

为什么不用 `dropna()` 了事：直接删会丢掉 11.6% 的样本，而且丢掉的恰好是信息不全的岗位——这类岗位往往是小公司或信息维护较差的企业，删掉会让样本偏向大企业，结论产生系统性偏差。有可靠来源可回填时，**回填优先于删除**。

第 3 步：脏值清洗

对 `学历要求` 和 `工作经验要求` 建立**合法枚举白名单**，白名单之外的取值（「11-16发布」「大专」混进经验列等）一律置为缺失，再用第 2 步的回填值补上。同时统一转义符：

> `"在校生\/应届生" → "在校生/应届生"`

第 4 步：类型转换（核心是把薪酬变成数字）

薪酬是本项目最费工的一步。原始写法至少有六类：

原始写法	含义	换算规则
`8千-1.2万`	月薪区间	下限 8,000 / 上限 12,000
`1.5-2万`	月薪区间（万元）	下限 15,000 / 上限 20,000
`15-20万/年`	年薪区间	÷12 换算为月薪
`1-2万·13薪`	月薪 + 13 薪	先按区间取值，再 ×13÷12 折算
`面议`	无报价	置为缺失
`3000-5000元/月`	明确单位	直接取数

统一产出三个数值字段：`月薪下限`、`月薪上限`、`月薪中点`。后续所有薪资统计统一用**中点**作为单一代表值，并**优先用中位数而非均值**（薪资分布右偏，均值会被少数高薪岗拉高）。

第 5 步：异常值处理（只标记，不删除）

两条规则：

1. **领域兜底**：月薪 < 1,000 元或 > 200,000 元，判定为明显错误（单位误读、年薪误当年薪），置为缺失。
2. **统计标记**：用 IQR 法（Q1 − 1.5×IQR, Q3 + 1.5×IQR）标出离群值，写入 `薪酬_异常` 列，但**不从表中删除**。

为什么离群值不删：30k–50k 的高薪岗位在这份数据里是真实存在的（架构师、资深工程师），删掉等于人为压缩薪资天花板，会让「这个行业能挣多少」的判断失真。右偏分布用中位数应对即可，不需要牺牲真实样本。真正需要处理的只是「单位错了」这类技术性错误。

3.3 清洗前后对比

指标	清洗前	清洗后
行数	4,100	**3,498**
列数	15	**19**（新增 城市/区县/经验年限/月薪三列/异常标记）
整行重复	602 条（14.7%）	0
学历缺失	476 条（11.6%）	**0**
经验缺失	475 条（11.6%）	**1 条（0.03%）**
薪酬可用率	文本，无法计算	**98.0%**（3,427 / 3,498 可算出月薪中点）

---

4. 探索性数据分析（EDA）

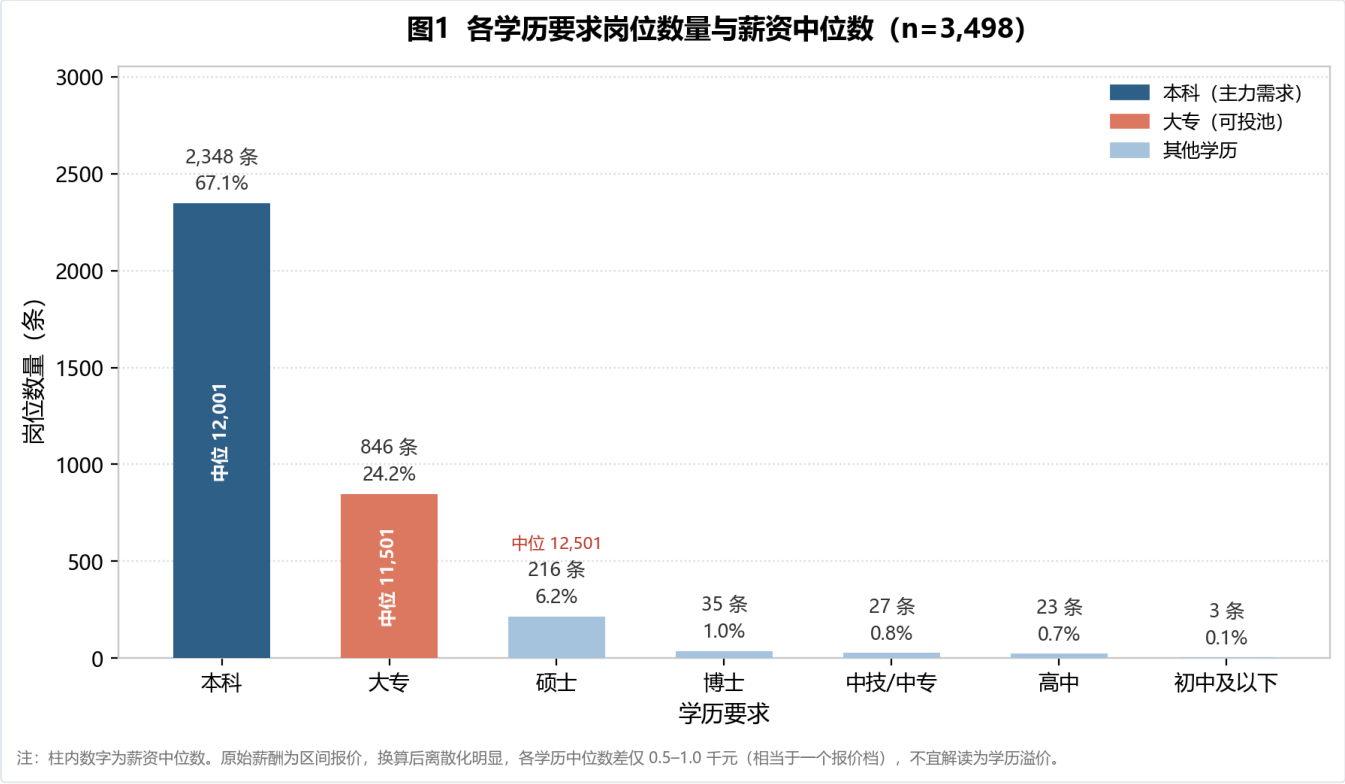
4.1 薪资整体画像

先看薪资的整体分布，建立基准认知。

分位	P10	P25	中位数	P75	P90
月薪（元）	7,500	9,000	**12,000**	15,001	25,000

均值 13,833 元高于中位数 12,000 元，差值约 1,800 元，是典型的**右偏分布**——大部分岗位集中在 1 万上下，少数高薪岗拉高了均值。所以本报告一律使用中位数描述「典型水平」：**这个方向 2022 年底的典型月薪是 1.2 万，不是 1.38 万。**

4.2 图 1：学历维度的门槛高度



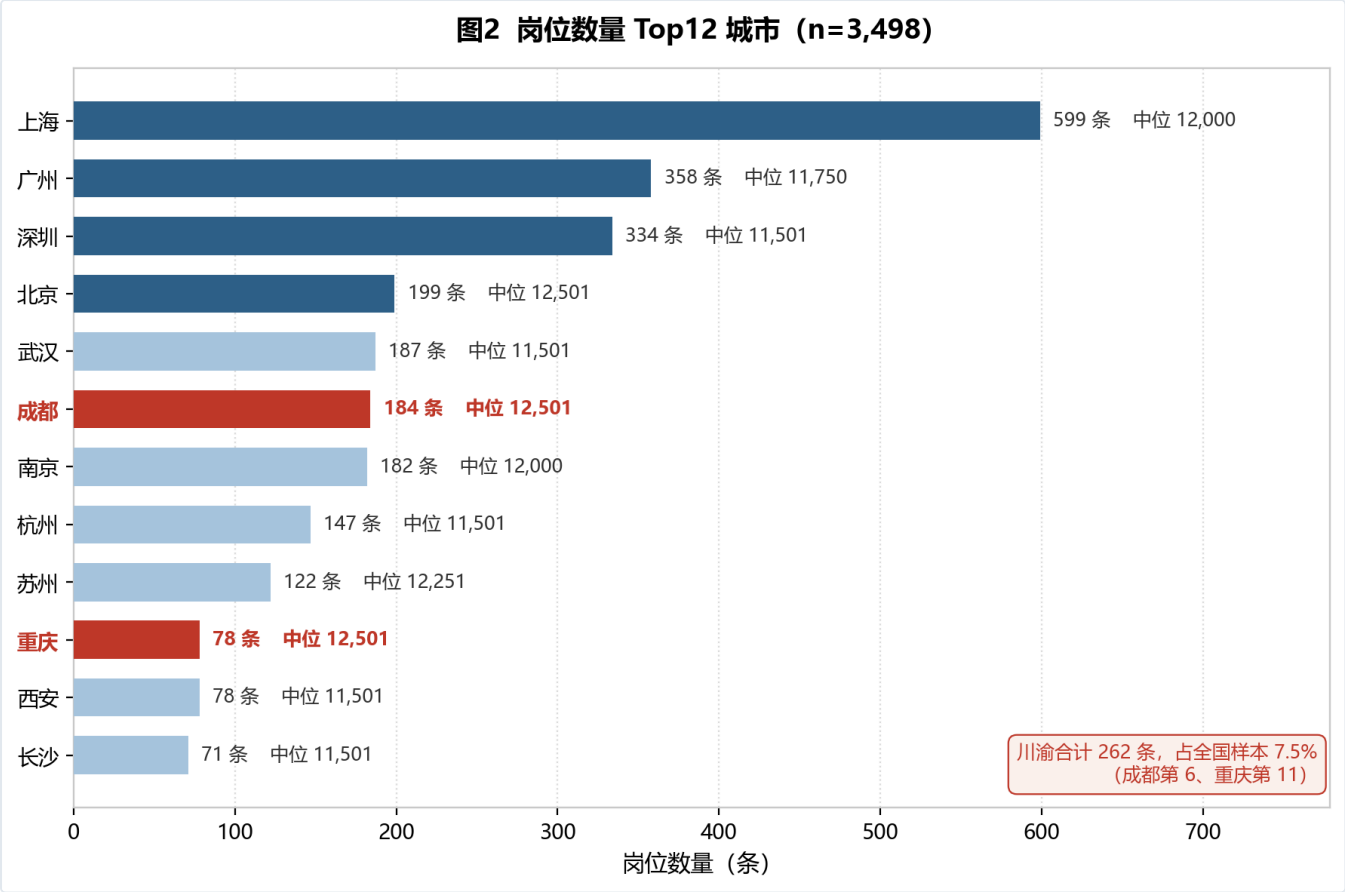
图表说明：柱状图，X 轴为学历要求，Y 轴为岗位数量；柱顶标注岗位数与占比，柱内标注该学历的薪资中位数。仅对样本量 ≥100 的学历标注薪资（博士 35 条、中技 27 条、高中 23 条样本过小，中位数无统计意义）。

读图结论：

- 本科要求 **2,348 条（67.1%）**，大专要求 **846 条（24.2%）**，两者合计 91.3%，构成市场基本盘。
- 把「要求不高于大专」的岗位全部算作专科可投池：846 + 27 + 23 + 3 = **899 条（25.7%）**；反过来说，**74.3% 的岗位明确要求本科及以上**。
- 薪资几乎没有分层：本科中位 12,001 元，大专中位 11,501 元，差 500 元（约 4.2%）。
- 需要说明的是，这里的「差距小」部分源于数据本身的离散化——薪酬是区间报价换算的，各档之间只差一个报价档位。所以正确的解读是「量级相当」，而不是「精确算出 4.2% 的溢价」。

这里刻意没有做双轴图：如果把薪资画在截断的右轴折线上，500 元的差距会被视觉放大成数倍，制造出一个不存在的「学历溢价」。图表应当忠实于数据，而不是服务于好看的结论。

4.3 图 2：城市维度的供给量级



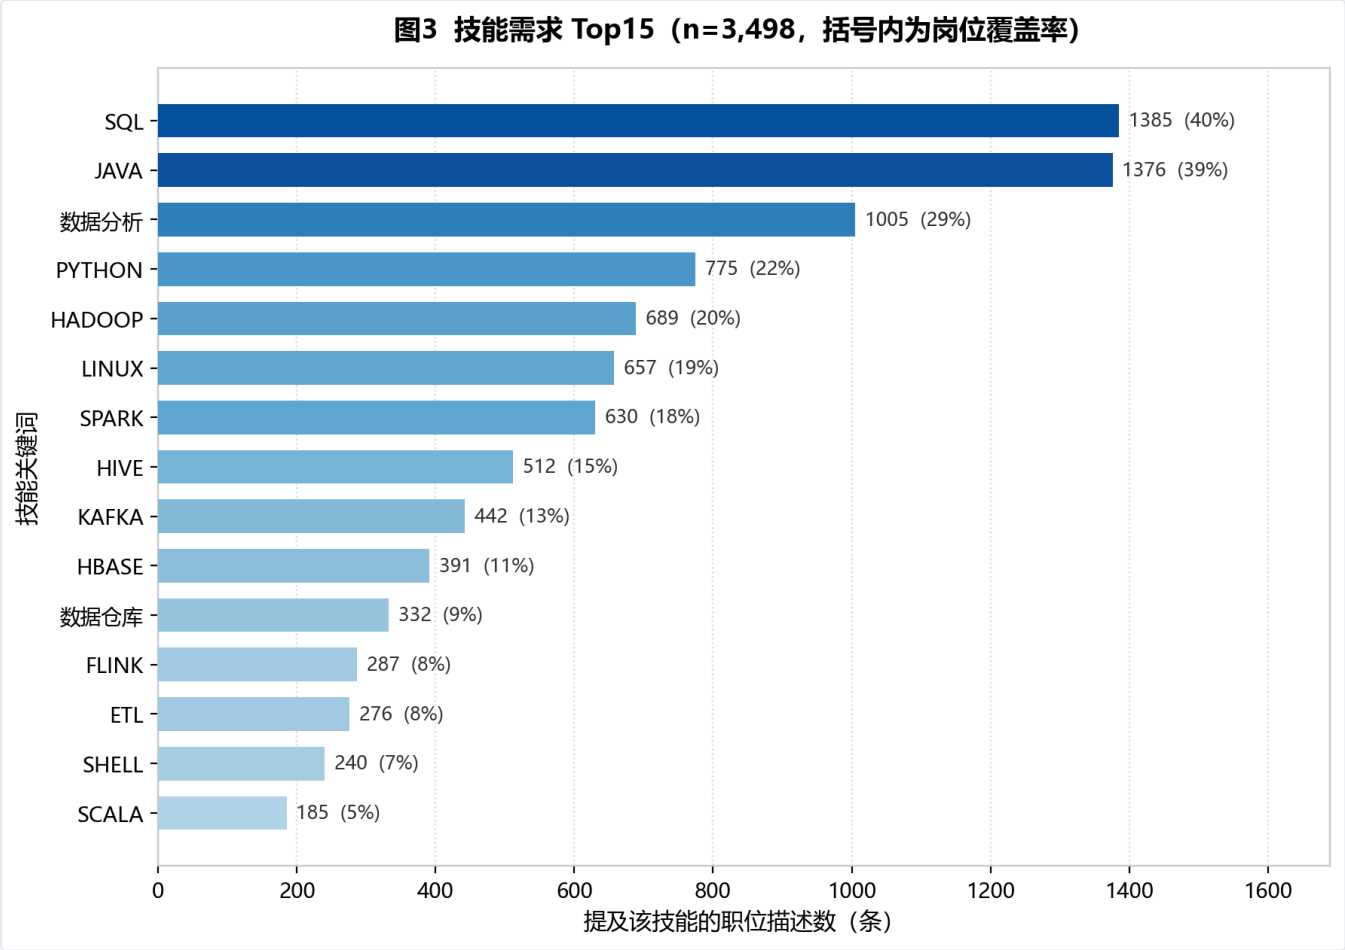
图表说明：横向条形图，Y 轴为城市（按岗位数降序取 Top12），X 轴为岗位数量；成都、重庆高亮为红色，条末标注岗位数与薪资中位数。

读图结论：

- 供给高度集中：上海 599、广州 358、深圳 334、北京 199，一线四城合计 **1,490 条（42.6%）**。
- 成都 **184 条**，全国第 6，超过杭州（147）；重庆 **78 条**，全国第 11。
- 川渝合计 **262 条，占 7.5%**，约为上海的 44%。
- 成都与重庆的薪资中位数均为 **12,501 元**，不低于北京，高于深圳、杭州（11,501 元）。

一个必须点明的事实：在川渝这 262 条里，同时满足「学历要求大专」+「无需经验」的岗位只有 **6 条**（成都 5、重庆 1）。也就是说，川渝本地几乎不存在「学历和经验双达标」的应届友好岗。这个数字不好看，但它解释了为什么「只投川渝」在应届阶段是高风险策略。

4.4 图 3：技能维度的优先级



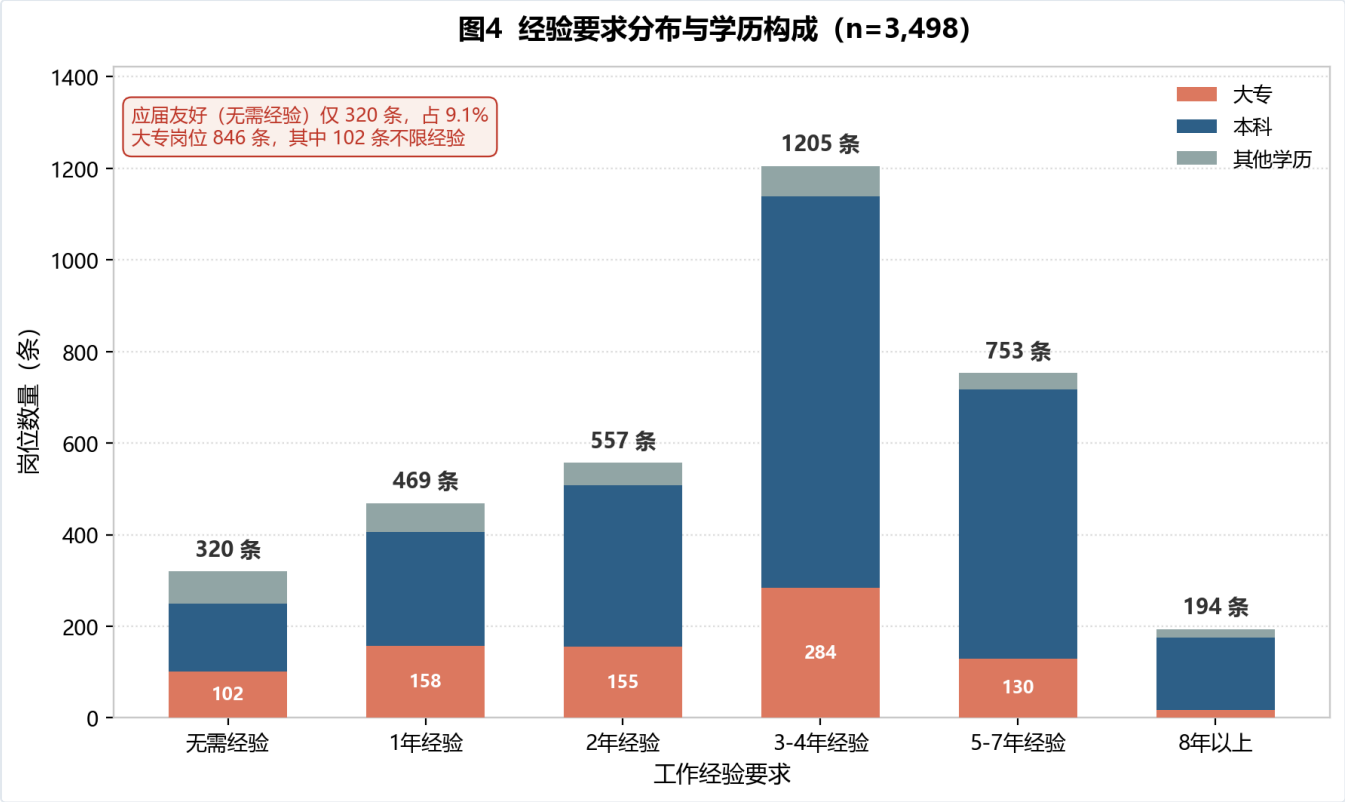
图表说明：横向条形图，X 轴为提及该技能的职位描述数，Y 轴为技能关键词 Top15；按需求强度做深浅渐变，括号内为岗位覆盖率（命中数 ÷ 3,498）。

读图结论：

- 第一梯队：**SQL 1,385 条（40%）、Java 1,376 条（39%）**，几乎并列。
- 第二梯队：**数据分析 1,005 条（29%）、Python 775 条（22%）**。
- 大数据技术栈：**Hadoop 689（20%）、Linux 657（19%）、Spark 630（18%）、Hive 512（15%）**。
- 加分组件：Kafka 442（13%）、HBase 391（11%）、Flink 287（8%）、ETL 276（8%）、Shell 240（7%）。

最反直觉的一点：Python 只排第 4，覆盖率 22%，不到 SQL 的六成。很多人（包括之前的我）默认「做数据先学 Python」，但这份数据说明：在大数据开发方向，**SQL 和 Java 才是入场券，Python 是加分项**。而 SQL 的学习成本远低于 Java，属于投入产出比最高的单项技能。

4.5 图 4：经验维度的结构



图表说明：堆叠柱状图，X 轴为工作经验要求（无需经验 → 8 年以上，已把原始 9 类枚举归并为 6 段），Y 轴为岗位数量，堆叠色块为学历分档（大专/本科/其他）。

读图结论：

- 需求重心在 **3–4 年经验段：1,205 条（34.4%）**。加上 5–7 年（753 条）与 8 年以上（194 条），**要求 3 年以上经验的岗位占 61.5%。**
- 应届友好（无需经验 / 在校生应届生）仅 **320 条（9.1%）**，其中大专 102 条、本科 147 条、其他 71 条。
- 大专 846 条岗位的经验分布：3–4 年 284 条、1 年 158 条、2 年 155 条、5–7 年 130 条、无需经验 102 条、8 年以上 17 条。

结论：市场对「经验」的定价权重明显高于学历——只要求应届的岗位不到十分之一，而要求 3 年以上的超过六成。对专科应届生而言，真正的窄门不是学历，是经验。

4.6 补充观察：企业类型的结构

作为背景信息补充（不作为主要结论）：民营企业 1,241 条（35.5%）、国企 901 条（25.8%）、已上市企业 700 条（20.0%）是前三类需求方。公司规模上，150–500 人（758 条）与 1000–5000 人（601 条）是主力，5000–10000 人的岗位薪资中位最高（14,583 元）。这些差异受行业构成与样本结构影响较大，仅作参考。

---

5. 业务结论与项目价值

5.1 四条结论

结论 1：学历卡的是「入场券」，不是「工资条」

专科可投池 899 条（25.7%），要求本科及以上的占 74.3%；但大专与本科的薪资中位数只差 500 元。

→ **动作**：投递时直接用「学历要求 ≤ 大专」做第一层筛选，把 899 条压到可管理规模，不要全量海投；遇到明确写「本科及以上」的岗位不要浪费投递额度；同时把简历的竞争力前移到技能与项目，因为学历已不是薪资差异的主要解释变量。

结论 2：川渝要「主攻成都 + 保留异地」，不能只投本地

成都 184 条全国第 6、中位 12,501 元；重庆 78 条全国第 11；川渝合计仅 7.5%。而川渝「大专 + 无需经验」只有 6 条。

→ **动作**：求职半径设三层——成都为主、重庆为辅、异地/远程保底。若坚持只投川渝，就必须把「1 年经验」段作为实际起点，用实习或项目去够门槛，而不是死守 9.1% 的应届友好岗。

结论 3：技能优先级是 SQL > Java > Python，不是「先学 Python」

SQL 40%、Java 39%、数据分析 29%、Python 22%；Hadoop/Hive/Spark 分别 20%/15%/18%。

→ **动作**：① SQL 刷到能独立写多表关联与窗口函数（覆盖率最高、成本最低）；② Python 达到 Pandas 清洗 + 可视化水平；③ Hadoop + Hive + Spark 跑通一个端到端离线数仓 demo（覆盖率约 1/5，但是面试区分度最高的部分）；④ Java 只在明确投大数据开发方向时重点补。

结论 4：用「项目」把经验栏从 0 填到 1

要求 3 年以上占 61.5%，应届友好仅 9.1%；「1 年经验」段 469 条（大专 158 条）是门槛与数量之间的平衡点。

→ **动作**：把课程项目包装成可核验的经历。本项目自身就是完整案例——4,100 条原始数据 → 3,498 条清洗 → 四维可视化 → 结论落表，可按「采集 / 清洗 / 分析 / 交付」四段写进简历，并给出具体数字与图表。这样在投「1 年经验」段岗位时，可用项目产出替代实际工龄，可投池从 102 条扩大到 260 条（大专经验 ≤1 年）。

5.2 项目价值

对求职的直接价值：把「我想做数据分析」这句空话，变成了一张有数字支撑的路线图——投哪 899 条、按什么顺序补技能、川渝机会量级多大、什么时候可以从应届岗切到 1 年经验岗。

对能力的证明价值：这个项目完整走过了数据分析的真实链路：不是只有 `groupby` 和画图，还包括判断「哪一列能回填哪一列」「离群值该不该删」「双轴图会不会误导」。这些判断比代码本身更能体现分析能力，也是面试中最容易被追问的部分。

---

6. 项目总结、局限性与后续优化方向

6.1 总结

本次分析基于 4,100 条招聘原始数据，经过去重、结构化回填、脏值清洗、类型转换、异常值标记五步处理，得到 3,498 条可用于分析的干净样本（学历字段完整率 100%、经验 99.97%、薪酬可用率 98.0%）。从学历、地域、技能、经验四个维度完成了 EDA，并提炼出四条可直接指导求职动作的结论。

最核心的发现是一个顺序问题：**在应届阶段，学历只是初筛条件，经验才是真正的门槛；而突破经验门槛的成本，远低于提升学历。** 这决定了接下来的时间应该投在项目上，而不是纠结于学历差距。

6.2 局限性

写清楚边界，结论才可信。以下五点直接影响适用范围：

1. **样本是主题垂直切片，不是全市场。** 44 类职位名称、69 家公司，`大数据开发工程师` 单一名称占 36.3%，技能词频会被模板化 JD 放大，不能外推为「全国大数据岗位技能需求」。
2. **快照时间较早。** 全部数据集中在 2022 年 11 月，与当前市场存在时间差，无法支持趋势类结论。
3. **薪资离散化严重。** 薪酬由区间报价换算，各分组中位数差异普遍小于一个报价档，图 1 的薪资对比只能说明「量级相当」，不能支撑精细的溢价测算。
4. **部分字段含推断成分。** 经验、学历各有 11.6% 的缺失值由 `地区经验学历` 列回填，回填准确但口径依赖原站点结构。
5. **川渝子样本极小。** 成都 184 条、重庆 78 条，其中「大专 + 无需经验」仅 6 条。按城市 + 学历 + 经验三重交叉时，结论只能作为方向参考，不能当统计结论使用。

需要补充说明：以上局限不影响「学历是门槛、经验权重更高、SQL 优先级最高」这三个方向性判断，因为它们在各细分切片中方向一致；但任何具体数值都不应脱离本数据集单独引用。

6.3 后续优化方向

方向	具体做法	预期收益
扩样本	接入 2–3 个新数据源（不同平台、不同月份）做纵向对比	从「快照」升级为「趋势」，结论时效性大幅提升
补维度	采集公司融资阶段、行业标签，做行业维度的薪资分层	解释「同样是 3 年经验，为什么薪资差 2 倍」
上模型	用职位描述做文本聚类（TF-IDF + K-Means），自动识别岗位类型	替代人工归类，能回答「这些岗位其实是几类」
做预测	以技能组合 + 经验 + 学历为特征，回归预测薪资区间	从描述性分析升级为预测性分析
工程化	清洗与出图脚本封装为可调度任务，结果落库（MySQL）	体现数据工程能力，而不只是分析能力

附：简历版项目描述（可直接粘贴）

大数据招聘岗位数据分析 ｜ Python · Pandas · Matplotlib ｜ 个人项目

- 独立完成 4,100 条招聘原始数据的清洗：去重 602 条、通过结构化字段回填 951 条缺失值、解析 6 类混乱薪酬格式为统一月薪，产出 3,498 条 × 19 字段分析主表，关键字段完整率 99.97% 以上、薪酬可用率 98%。
- 从学历、地域、技能、经验四维度完成 EDA 与可视化，输出 4 张图表与完整报告，所有结论与脚本输出逐项对应、可复现。
- 核心结论：专科可投岗位占 25.7%（899 条），而要求本科以上占 74.3%；大专与本科薪资中位数仅差 500 元——学历影响初筛而非定价；技能需求 SQL 40% > Java 39% > Python 22%，据此调整学习优先级。
- 针对目标地域（川渝）做交叉分析，发现该地区「大专 + 无需经验」岗位仅 6 条，据此将求职策略调整为「成都为主 + 异地保底」，并把可投池从 102 条扩展到 260 条。

本项目所有统计数字均由 `data/clean_jobs_3498.csv` 全量实算得出，清洗脚本见 `src/bigdata_job_clean_eda.py`，绘图脚本见 `src/job_visualization.py`，可一键复现。